

Fundamentos de IA para ciencia de datos

Daniel Aguirre

Vocabulario

ChatGPT

Google Colab

Modelos de Lenguaje

N-gramas

Contexto

Modelo Black-Box / White-Box

NLP

Tokens

AGI

Git/GitHub

Corpus

¿Qué es inteligencia artificial?

Un campo de la informática (?) que crea sistemas y computadoras capaces de realizar tareas que normalmente requieren inteligencia humana

Tipos de inteligencia artificial

Existen varias formas de clasificar la inteligencia artificial.


Las 3 formas más comunes son:

1. **Por capacidad**

2. Por funcionamiento

3. Por enfoque técnico

¿Qué tan general es?



Fuente: *Understanding ANI, AGI and ASI in AI, Medium*


Tipos de inteligencia artificial

Existen varias formas de clasificar la Inteligencia Artificial.

Las 3 formas más comunes son:

1. Por capacidad
2. **Por funcionamiento**
3. Por enfoque técnico

Clasificación de Arend Hintze




Fuente: *Advisory*

Tipos de inteligencia artificial

Existen varias formas de clasificar la Inteligencia Artificial.

Las 3 formas más comunes son:

1. Por capacidad
2. Por funcionamiento
3. **Por enfoque técnico**





Modelos black-box

Un modelo de caja negra (Black Box) es un sistema o dispositivo que se analiza exclusivamente a partir de sus entradas (inputs) y salidas (outputs), sin conocer, importar o comprender su funcionamiento interno ni los mecanismos que generan dicho resultado.

Modelando la montaña rusa



Input





?

Output

Modelando la montaña rusa



Input





?

Output

Modelando la montaña rusa




Input




Output


Modelando la montaña rusa




Modelando la montaña rusa




Modelando la montaña rusa



Modelando la montaña rusa



75%



25%


Workshop 1

Actividad 1: Diseñe un modelo caja blanca para modelar una montaña rusa en Google Colab. En el Github del curso puede encontrar más información.


Procesamiento de Lenguaje Natural (NLP)

Rama de la inteligencia artificial que permite a las computadoras entender, interpretar y generar lenguaje humano en cualquiera de sus formas: **texto**, voz o audio transcrito


Breve historia de NLP






¿Cómo modelar el lenguaje?



¿Cómo modelar el lenguaje?





¿Cómo modelar el lenguaje?



Input

Output

Modelos n-gramas




Predecimos la siguiente
palabra usando las **n-1**
palabras anteriores

Input

Output

Modelos n-gramas

“ Do you want to go
to the ”



Modelo n-grama




Palabra siguiente	$P(w \mid \text{contexto})$
store	0.22
gym	0.16
bank	0.09
park	0.07
movies	0.06
beach	0.04
library	0.03
mall	0.02
...resto del vocabulario	0.31
Total	1.00

Input

Output

Modelos n-gramas

“ Do you want to go
to the ”



Modelo 2-grama




Palabra siguiente	$P(w \mid \text{"the"})$
store	0.22
gym	0.16
bank	0.09
park	0.07
movies	0.06
beach	0.04
library	0.03
mall	0.02
...resto del vocabulario	0.31
Total	1.00

Input

Output

Modelos n-gramas

“ Do you want to go
to the ”



Modelo 3-grama




Palabra siguiente	$P(w \mid \text{"to the"})$
store	0.031
gym	0.024
bank	0.019
park	0.016
movies	0.013
beach	0.010
library	0.008
mall	0.006
...resto del vocabulario	0.873
Total	1.00

Input

Output

Entrenamiento de modelos n-gramas

Corpus



Entrenamiento de modelos n-gramas

Corpus



quiero ir al cine



quiero ir al parque



quiero comer algo

Entrenamiento de modelos n-gramas

Corpus



<s> quiero ir al cine </s>

Paso 1
Añadir marcadores



<s> quiero ir al parque </s>



<s> quiero comer algo </s>

Entrenamiento de modelos n-gramas

Corpus



<s>|quiero|ir|al|cine|</s>

6 tokens

Paso 2
Tokenizar



<s>|quiero|ir|al|parque|</s>

6 tokens



<s>|quiero|comer|algo|</s>

5 tokens

Entrenamiento de modelos n-gramas

Corpus



<s> → quiero quiero → ir ir → al al → cine cine → </s>

Paso 3

Extraer n-gramas



<s> → quiero quiero → ir ir → al al → parque parque → </s>

Ejemplo con 2-gramas



<s> → quiero quiero → comer comer → algo algo → </s>

Entrenamiento de modelos n-gramas

Corpus



Paso 4
Contar



Token	$C(w)$
<s>	3
quiero	3
ir	2
al	2
cine	1
parque	1
comer	1
algo	1
</s>	3

Bigrama	$C(w_{i-1}, w_i)$
<s> quiero	3
quiero ir	2
quiero comer	1
ir al	2
al cine	1
al parque	1
cine </s>	1
parque </s>	1
comer algo	1
algo </s>	1

Ejemplo con 2-gramas



Entrenamiento de modelos n-gramas

Corpus



Paso 5
Dividir




Ejemplo con 2-gramas




Contexto	Siguiente	Cálculo	P
<s>	quiero	3/3	1.00
quiero	ir	2/3	0.67
quiero	comer	1/3	0.33
ir	al	2/2	1.00
al	cine	1/2	0.50
al	parque	1/2	0.50
cine	</s>	1/1	1.00
parque	</s>	1/1	1.00
comer	algo	1/1	1.00
algo	</s>	1/1	1.00

Predicción con modelos n-gramas



Contexto	Siguiente	P
<s>	quiero	1.00
quiero	ir	0.67
quiero	comer	0.33
ir	al	1.00
al	cine	0.50
al	parque	0.50
cine	</s>	1.00
parque	</s>	1.00
comer	algo	1.00
algo	</s>	1.00

Predicción con modelos n-gramas



Contexto	Siguiente	P
<s>	quiero	1.00
quiero	ir	0.67
quiero	comer	0.33
ir	al	1.00
al	cine	0.50
al	parque	0.50
cine	</s>	1.00
parque	</s>	1.00
comer	algo	1.00
algo	</s>	1.00

Workshop 1

Actividad 2: Cree un modelo bigrama en google colab que permita predecir la siguiente palabra. El corpus está en GitHub.

Vocabulario

ChatGPT

Google Colab

Modelos de Lenguaje

N-gramas

Contexto

Modelo Black-Box / White-Box

NLP

Tokens

AGI

Git/GitHub

Corpus