

Fundamentos de IA para ciencia de datos II

Daniel Aguirre

Vocabulario sesión pasada

ChatGPT

Google Colab

Modelos de Lenguaje

N-gramas

Contexto

Modelo Black-Box / White-Box

NLP

Tokens

AGI

Git/GitHub

Corpus


Vocabulario

A word cloud containing various terms related to AI and machine learning. The words are arranged in a non-uniform, scattered pattern across the page. The terms include:

- One-hot encoding
- HuggingFace
- Redes Neuronales
- LLM
- Temperatura
- LoRA
- Embedding
- Fine tuning
- Decoder
- Few-shot/Zero-shot
- Transformers
- GPU
- API
- System prompt

Breve historia de NLP

1980



Modelos N-Gramas



2000



Large Language Models
(LLMs)

Actualidad




Breve historia de NLP



En este tiempo nacieron
arquitecturas de redes neuronales
importantes:

- RNN
- LSTMs

Breve historia de NLP



En este tiempo nacieron
arquitecturas de redes neuronales
importantes:

- RNN
- LSTMs

Back to the basics...

Quiero predecir el salario por hora de una persona en función de la edad...



salario = **parámetro** x 25 años

Back to the basics...

Quiero predecir el salario por hora de una persona en función de la edad...



$$\text{salario} = \text{parámetro} \times 25 \text{ años}$$

Podemos, por ejemplo, encontrar el parámetro revisando una base de datos de personas de 25 años que reportaron su salario.

Back to the basics...

Quiero predecir el salario por hora de una persona en función de la edad...



$$\text{salario} = 333.52 \times 25 \text{ años}$$

Se espera que Fry gane, entonces,
un salario de 8,338 pesos por hora
(eso es un salario mínimo de 2026)

Back to the basics...

Quiero predecir el salario por hora de una persona en función de la edad...
y la educación



salario = **parámetro1** x 25 años + **parámetro2** x 5 años de edu

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

parámetro = peso

Back to the basics...

¿Qué es una regresión lineal?

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

¿Qué ocurre si le aplicamos las siguientes funciones?

$$f(z) = \frac{1}{1 + e^{-z}}$$

Regresión Logística/Neurona

¡Esto se llama función de activación!

$$f(z) = \max(0, z)$$

Neurona

$$f(x) = x$$

Neurona

Back to the basics...

¿Qué es una regresión lineal?


$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2$$

¿Qué ocurre si le aplicamos las siguientes funciones?

$$f(z) = \frac{1}{1 + e^{-z}}$$

$$f(z) = \max(0, z)$$

$$f(x) = x$$



Back to the basics...





Fry

25 años

5 años de
educación

salario = **parámetro0**
+ **parámetro1** x edad
+ **parámetro2** x años de edu

sueño = **parámetro3**
+ **parámetro4** x edad
+ **parámetro5** x años de edu




Back to the basics...





Fry

25 años (x_1)

5 años de
educación (x_2)



Es equivalente a



¡Esto ya es una red neuronal!


Back to the basics...



Fry

25 años (x_1)


5 años de
educación (x_2)



Modelo black-box

Que ponemos en la capa final?

Breve historia de NLP




En este tiempo nacieron
arquitecturas de redes neuronales
importantes:

- RNN
- LSTMs

Word2Vec

Las palabras se representan como vectores (**embeddings**)



Simplificación para nosotros:

- Los vectores son colores

adult = 

woman = 

boy = 

Word2Vec

Resultados principales:

- Operaciones entre vectores (colores) de palabras tienen sentido semántico

Vocabulario

hombre = 

reino = 

rey = 

...

hombre + reino = rey



+



=




≈




Word2Vec

Resultados principales:

- Operaciones entre vectores (colores) de palabras tienen sentido semántico



Breve historia de NLP




Problemas de modelos antiguos

¿Cuál es el mayor problema de los modelos n-gramas al predecir la siguiente palabra?

¡El contexto!

“ Do you want to go
to the ”



Modelo 2-grama



Palabra siguiente $P(w \mid \text{"the"})$

store	0.22
gym	0.16
bank	0.09
park	0.07
movies	0.06
beach	0.04
library	0.03
mall	0.02
...resto del vocabulario	0.31
Total	1.00

¿Cómo solucionaríamos con modelos n-gramas para utilizar todo el contexto?

Problemas de modelos antiguos

“La cafetería del campus se negó a venderme un café con leche porque solo sirve bebidas veganas. Al final, me dieron agua tibia. Su servicio era tan bueno como sus precios y calidad.”

Objetivo:

- Clasificar reseñas como positivas o negativas
- Responder preguntas como: “¿La cafetería vende productos lácteos?”

Problemas:

1. Cada reseña es de distinto tamaño
2. El lenguaje es ambiguo. ¿“Su” a qué se refiere?

Problemas de modelos antiguos

“La **cafetería** del campus se negó a venderme un café con leche porque solo sirve bebidas veganas. Al final, me dieron agua tibia. **Su** servicio era tan bueno como sus precios y calidad.”

Objetivo:

- Clasificar reseñas como positivas o negativas
- Responder preguntas como: “¿La cafetería vende productos lácteos?”



Problemas:

1. Cada reseña es de distinto tamaño
2. El lenguaje es ambiguo. ¿“Su” a qué se refiere? **¡Atención!**

Transformers

"Attention Is All You Need"^[1] is a 2017 landmark^{[2][3]} research paper in machine learning authored by eight scientists working at Google. The paper introduced a new deep learning architecture known as the transformer, based on the attention mechanism proposed in 2014 by Bahdanau et al.^[4] It is considered a foundational^[5] paper in modern artificial intelligence, and a main contributor to the AI boom, as the transformer approach has become the main architecture of a wide variety of AI, such as large language models.^{[6][7]} At the time, the focus of the research was on improving Seq2seq techniques for machine translation, but the authors go further in the paper, foreseeing the technique's potential for other tasks like question answering and what is now known as multimodal generative AI.^[1]

As of 2025, the paper has been cited more than 173,000 times,^[10] placing it among the top ten most-cited papers of the 21st century.^[11]



Transformers

1. Tokenización

"banco del rio"

Tokens:	"banco"	"del"	"rio"
Token IDs:	141	53	871

Actividad: Use el tokenizer de ChatGPT para encontrar la división de tokens que hace a la frase "Hola soy Daniel", qué ocurre si usamos "daniel" en minúscula?

Actividad: Abra ChatGPT. Pregúntele cuál es el tamaño del vocabulario. Revise en el tokenizer cuales son los token IDs de los tokens? Que significan los token IDs? Cual es su funcionalidad?

Transformers

1. Tokenización

Tokens:
Token IDs:

"banco"
141

"del"
53

"rio"
871


2. One-hot encoding

	banco	del	rio
	0	0	:
	0	:	0
	.	53 1	.
	:	.	:
	:	.	:
141	1	.	0
	:	0	871 1
	0	0	0

Transformers

3. Crear **embeddings** con una red neuronal



banco	del	rio
0	0	$\vdots$
0	$\vdots$	0
$\cdot$	1	$\cdot$
$\cdot$	$\cdot$	$\cdot$
1	$\cdot$	0
$\vdots$	0	1
0	0	0



Transformers

3. Crear **embeddings** con una red neuronal

banco	del	rio
0	0	⋮
0	⋮	0
⋮	1	⋮
⋮	⋮	⋮
1	⋮	0
⋮	0	1
0	0	0



banco	del	rio
1.5	1	4
3	2	5



 = **X**

Ejemplo con 2 dimensiones

Transformers

3. Crear **embeddings** con una red neuronal

banco	del	rio
0	0	⋮
0	⋮	0
⋮	1	⋮
⋮	⋮	⋮
⋮	⋮	0
1	⋮	1
⋮	0	0
0	0	0



banco	del	rio
1.5	1	4
3	2	5



 = **X**

Ejemplo con 2 dimensiones

Transformers

3. Crear **embeddings** con una red neuronal

banco	del	rio
0	0	⋮
0	⋮	0
⋮	1	⋮
⋮	⋮	⋮
1	⋮	0
⋮	0	1
0	0	0



banco	del	rio
1.5	1	4
3	2	5



 = **X**

Ejemplo con 2 dimensiones

Transformers

3. Crear **embeddings** con una red neuronal

banco	del	rio
0	0	$\vdots$
0	$\vdots$	0
$\cdot$	1	$\cdot$
$\cdot$	$\cdot$	$\cdot$
$\cdot$	$\cdot$	$\cdot$
1	$\cdot$	0
$\cdot$	0	1
0	0	0




banco	del	rio
1.5	1	4
3	2	5

 = **X**

Ejemplo con 2 dimensiones

Transformers

4. Crear auto-atención



Transformers

5. Volver a iterar paso (4) si se quiere...


banco




del



rio




Tipos de transformers



*Illustrative example, exact model architecture may vary slightly


Ejemplos

Que necesito hacer si quiero clasificar la reseña? ¡Encoder!



Ejemplos

Que necesito hacer si quiero predecir un texto? ¡Decoder!



Ejemplos

De forma general, se distinguen:

- Encoder-only (BERT, RoBERTa) → para clasificación, embeddings, búsqueda semántica, NER, etc.
- Decoder-only (GPT, Llama, Claude) → para generación de texto, lo que la mayoría llama "LLM" hoy en día.
- Encoder-decoder (T5, BART) → para tareas de secuencia a secuencia (traducción, resumen).

¿Cómo se entrenan?



Se entrenan de forma similar, pero con distinto objetivo... Esto se llama **preentrenamiento**

	Encoder (BERT)	Decoder (GPT)
Atención	Bidireccional	Causal (no ve el futuro)
Objetivo	Predecir tokens tapados (MLM)	Predecir el siguiente token
Datos	No etiquetados	No etiquetados
Señales por pasada	~15% de los tokens	Todos los tokens
Sirve para	Clasificar, embeddings, búsqueda	Generar texto

El preentrenamiento **no** usa etiquetas en ninguno de los dos casos.
Los datos etiquetados llegan en el **fine-tuning**


¿Cómo se entrenan?

En cualquiera de los dos casos, no entraremos a profundidad. Esta parte la suelen hacer laboratorios que tienen recursos computacionales altos!




¿Cómo se entrenan?

En cualquiera de los dos casos, no entraremos a profundidad. Esta parte la suelen hacer laboratorios que tienen recursos computacionales altos!




Con cientos, incluso miles de GPUs



¿Cómo se entrenan?

Lo que nos importa es que hay una etapa de **fine-tuning**, donde estos modelos se adaptan a tareas.



Encoder → adaptarlo a una tarea concreta



Decoder → instruction tuning y RLHF (lo que convierte GPT en ChatGPT)



¿Cómo se entrenan?

Lo que nos importa es que hay una etapa de **fine-tuning**, donde estos modelos se adaptan a tareas.

	Fine-tuning en encoder	Fine-tuning en decoder
Qué se ajusta	Cabeza de clasificación nueva	El mismo objetivo de siempre (siguiente token)
Con qué datos	Etiquetados por tarea	Pares instrucción-respuesta
Qué se gana	Sabe hacer <i>una</i> tarea	Sabe <i>comportarse</i>
Nombre	Fine-tuning por tarea	Instruction tuning, SFT, RLHF

¿Cómo se entrenan?

Lo que nos importa es que hay una etapa de **fine-tuning**, donde estos modelos se adaptan a tareas.



¿Por qué pueden ser de distinto tamaño si ambos clasifican reseñas?

¿Cómo se entrenan?

Lo que nos importa es que hay una etapa de **fine-tuning**, donde estos modelos se adaptan a tareas.



100M de pesos/parámetros



1500M de pesos/parámetros



Cantidad de neuronas/parámetros/pesos!.


Distinta arquitectura...

¿Cómo se utilizan?

A través de APIs (un servidor con el modelo + peticiones HTTP):

- De terceros como OpenAI, Google, Anthropic, Groq
- Localmente como Ollama (desarrollo) o vLLM (producción)

A través de librerías como `transformers`



Workshop 2

Cómo se utilizan los LLMs


Actividad 1: Vía API de terceros

¿Cómo se utilizan?

A través de APIs (un servidor con el modelo + peticiones HTTP):

- De terceros como OpenAI, Google, Anthropic, Groq
- Localmente como Ollama (desarrollo) o vLLM (producción)

A través de librerías como `transformers`



Workshop 2

Cómo se utilizan los LLMs

Actividad 2: Vía API propia

¿Cómo se utilizan?

A través de APIs (un servidor con el modelo + peticiones HTTP):

- De terceros como OpenAI, Google, Anthropic, Groq
- Localmente como Ollama (desarrollo) o vLLM (producción)

A través de librerías como `transformers`



Transformers



Workshop 2

Cómo se utilizan los LLMs


Actividad 3: Vía librería como `transformers`

¿Cómo se utilizan?

A través de APIs (un servidor con el modelo + peticiones HTTP):

- De terceros como OpenAI, Google, Anthropic, Groq
- Localmente como Ollama (desarrollo) o vLLM (producción)

A través de librerías como transformers




¿Cómo se utilizan?

A través de APIs (un servidor con el modelo + peticiones HTTP):

- De terceros como OpenAI, Google, Anthropic, Groq
- Localmente como Ollama (desarrollo) o vLLM (producción)

A través de librerías como `transformers`




¿Cómo se utilizan?

A través de APIs (un servidor con el modelo + peticiones HTTP):

- De terceros como OpenAI, Google, Anthropic, Groq
- Localmente como Ollama (desarrollo) o vLLM (producción)

A través de librerías como `transformers`



Workshop 2

Cómo se utilizan los LLMs

Actividad 4: Qué hacer cuando un modelo es más grande que mis recursos computacionales?

¿Cómo se utilizan?


A través de APIs (un servidor con el modelo + peticiones HTTP):

- De terceros como OpenAI, Google, Anthropic, Groq
- Localmente como Ollama (desarrollo) o vLLM (producción)

A través de librerías como `transformers`




Transformers



¿Cómo se utilizan?

Parámetros del modelo:



token IDs
(todo el vocabulario)

- **Temperatura:** aplanar o agudizar la distribución (0 = siempre el máximo)
- **Top k:** se queda con los k tokens más probables
- **Top p:** se queda con los que suman p de probabilidad (se adapta al contexto)
- **Max tokens:** corta por longitud
- **Stop:** corta al aparecer cierto texto

Workshop 2

Cómo se utilizan los LLMs

Actividad 5: Configurando parámetros del modelo

¿Cómo se mejoran?

- Prompting: instrucciones claras, ejemplos (few-shot), system prompt (gratis e inmediato)
- Contexto: darle la información en el prompt (distintas formas de darle contexto)
- Fine-tuning / LoRA: ajustar los pesos (costoso, requiere datos)

Workshop 3

Cómo se mejoran los LLMs

Actividad 1: Vía prompting

¿Cómo se mejoran?

- Prompting: instrucciones claras, ejemplos (few-shot), system prompt (gratis e inmediato)
- Contexto: darle la información en el prompt (distintas formas de darle contexto)
- Fine-tuning / LoRA: ajustar los pesos (costoso, requiere datos)

Workshop 3

Cómo se mejoran los LLMs

Actividad 2: Vía contexto

¿Cómo se mejoran?

- Prompting: instrucciones claras, ejemplos (few-shot), system prompt (gratis e inmediato)
- Contexto: darle la información en el prompt (distintas formas de darle contexto)
- Fine-tuning / LoRA: ajustar los pesos (costoso, requiere datos)

Workshop 3

Cómo se mejoran los LLMs

Actividad 3: Vía fine-tuning/LoRA