

Fine-tuning y RAGs

El problema

Los LLMs son increíbles, pero

1. No conocen los datos específicos de su empresa, negocio, o tema de interés
2. Conocimiento desactualizado
3. Pueden alucinar

SOLUCIÓN: Fine-tuning o RAG

Fine-tuning

Es una técnica que consiste en tomar un modelo pre-entrenado y adaptarlo para una tarea específica.

Hay distintas formas:

1. **Full Fine-tuning:** Se actualizan todos los parámetros del modelo.
2. **Parameter-Efficient Fine-Tuning:** Técnicas que ajustan sólo una pequeña parte del modelo. La más usada: **LoRA (Low-Rank Adaptation)**

Ejemplos: Chatbots de atención al cliente (e.g., Rappi, Uber) que tengan contexto específico (e.g., políticas de devolución, productos específicos, etc.)

RAGs

Combina dos componentes:

1. **Retrieval (Recuperación):** Busca información relevante en una base de datos.
2. **Generation (Generación):** Usa esa información para generar una respuesta. Es como darle al modelo un “libro abierto durante el examen”

Cuales tipos de modelos interactúan aquí? Encoder/Decoder?


Como funciona RAG

Paso 0. Cada documento, con un encoder, lo transformamos en vector y lo guardamos en una base de datos vectorial.

Doc 1: "El gato duerme en el sofá"

Doc 2: "El perro corre en el parque"

Doc 3: "El felino descansa en el mueble"




Doc 1 → [0.8, 0.2, 0.1, 0.9, ...]


Doc 2 → [0.1, 0.7, 0.9, 0.2, ...]

Doc 3 → [0.7, 0.3, 0.1, 0.8, ...]

Back to Transformers (lo que vimos)




Modelos Encoder de texto a vector




Como funciona RAG

Paso 0. Cada documento, con un encoder, lo transformamos en vector y lo guardamos en una base de datos vectorial.

Doc 1: "El gato duerme en el sofá"
Doc 2: "El perro corre en el parque"
Doc 3: "El felino descansa en el mueble"



Doc 1 → [0.8, 0.2, 0.1, 0.9, ...]
Doc 2 → [0.1, 0.7, 0.9, 0.2, ...]
Doc 3 → [0.7, 0.3, 0.1, 0.8, ...]



PINECONE / CHROMA / WEAVIATE		
ID	Vector	Metadata
doc1	[0.8, 0.2, ...]	{page: 1}
doc2	[0.1, 0.7, ...]	{page: 2}
doc3	[0.7, 0.3, ...]	{page: 3}

Como funciona RAG

Usuario pregunta algo



1. Convertir pregunta a vector
(**embedding**)



2. Buscar documentos similares en
base de datos vectorial



3. Recuperar los **top K** fragmentos
más relevantes



4. Enviar al **LLM**: [contexto
recuperado + pregunta original]



5. LLM genera respuesta basada en
ese contexto