


OCR + LLM

Extracción inteligente de datos de documentos



La revolución del OCR con IA Generativa

El OCR tradicional extrae texto, pero los LLM lo comprenden y estructuran. La combinación de OCR con modelos de lenguaje crea sistemas que no solo leen documentos, sino que los interpretan y organizan según nuestras necesidades específicas.

Esta fusión permite procesar cualquier documento físico como si fuera una base de datos estructurada, democratizando el acceso a información atrapada en papel o PDFs.

El paradigma evoluciona de "extraer texto" a "entender documentos", creando flujos de trabajo que automatizan completamente el procesamiento de facturas, contratos, reportes médicos y cualquier documento empresarial.

Comparativa de costos: OCR tradicional vs moderno

Servicios Cloud tradicionales

- Google Cloud Vision: \$1.50/1000 páginas
- AWS Textract: \$1.50/1000 páginas
- Azure Document Intelligence: \$1.50/1000 páginas

Nuevas alternativas

- Mistral OCR: \$1.00/1000 páginas
- Reducto API: Pricing bajo demanda

Tesseract + LLM local:

- Hardware: \$0 (servidores existentes)
- Licencias: \$0 (código abierto)
- Procesamiento: Ilimitado

ROI: 95%+ ahorro vs servicios cloud

Tesseract OCR: La base open source

Tesseract es el motor OCR open source más maduro del mundo, desarrollado originalmente por HP y mantenido por Google desde 2006. Su combinación con LLM crea sistemas de extracción de datos prácticamente gratuitos.

Ventajas clave

- **Costo cero:** Sin límites de páginas ni API calls
- **Control total:** Personalización y fine-tuning
- **104 idiomas:** Soporte multilingüe nativo
- **LSTM neural networks:** Precisión moderna



Documentación:

github.com/tesseract-ocr/tesseract

Para empresas: Sistema auto-hospedado sin dependencias externas

Arquitectura Tesseract + LLM

Pipeline híbrido de extracción inteligente:

1. **Análisis del documento ejemplo** → LLM define estructura JSON automáticamente
2. **OCR batch con Tesseract** → Extracción de texto sin costo
3. **Procesamiento con LLM** → Mapeo inteligente a campos estructurados
4. **Validación y salida** → JSON estructurado con metadatos

Componentes técnicos

- **pytesseract**: Wrapper Python optimizado
- **Groq API**: LLM rápido para estructuración
- **pdf2image**: Conversión PDF automática
- **Batch processing**: Escalamiento industrial

Resultado: Sistema que aprende del primer documento y aplica la misma estructura a miles de documentos similares

Casos de uso: Tesseract + LLM



Facturas y recibos

- Extracción de campos clave automática
- Validación de totales y cálculos
- Integración con sistemas ERP



Formularios empresariales

- Procesamiento de aplicaciones
- Digitización de encuestas físicas
- Automatización de workflows



Documentos médicos

- Historiales clínicos estructurados
- Reportes de laboratorio
- Prescripciones médicas

Ventaja competitiva: Sin límites de volumen ni costos variables. Perfecto para grandes volúmenes de documentos similares.

Mistral OCR: El nuevo estándar

Mistral OCR representa la evolución del OCR con IA nativa, procesando 2,000 páginas por minuto con comprensión contextual de elementos como tablas, ecuaciones y gráficos complejos.

Capacidades avanzadas

- **Multimodal nativo:** Texto, tablas, imágenes, ecuaciones
- **Multilingual:** 100+ idiomas sin configuración
- **Self-hostable:** Deploy local disponible
- **API simple:** Integración en minutos



Documentación:

mistral.ai/news/mistral-ocr

Pricing: \$1.00/1000 páginas

Performance: 2K páginas/minuto

Arquitectura Mistral OCR

Pipeline nativo multimodal:

1. Upload directo → PDF/imágenes a API Mistral
2. OCR inteligente → Detección automática de elementos
3. Structured output → Markdown + JSON estructurado
4. LLM analysis → Extracción de insights y metadatos

Ventajas vs competencia

- **94.9% accuracy** vs 88.49% (Gemini 2.0)
- **Incluye images:** Extracción de imágenes embebidas

Ideal para: Documentos complejos con layouts variables, reportes científicos, y procesamiento que requiere alta precisión inmediata

Implementación práctica: Mistral OCR

Setup mínimo

```
from mistralai import Mistral
client = Mistral(api_key=api_key)

# Upload y procesamiento
uploaded_file = client.files.upload(
    file=pdf_content,
    purpose="ocr"
)

response = client.ocr.process(
    document=DocumentURLChunk(...),
    model="mistral-ocr-latest"
)
```

Outputs múltiples

- **Markdown estructurado** para análisis
- **Imágenes extraídas** como archivos separados
- **JSON metadata** con estructura detectada
- **Full text** para búsqueda y indexación

Automatización completa: De PDF a datos estructurados en una sola llamada API

Reducto: OCR especializado para documentos complejos

Reducto se enfoca en los casos más difíciles: periódicos antiguos, documentos con layouts complejos y estructuras no estándar donde otros sistemas fallan.

Especialización única

- **Agentic OCR:** Auto-corrección con múltiples pasadas
- **Complex layouts:** Multi-columna, tablas anidadas
- **Vision + LLM:** Combinación de modelos especializados
- **Custom schemas:** Definición de outputs específicos

 Más información:

reducto.ai

Target: Empresas Fortune 10

Fortaleza: Documentos "imposibles"

Pricing: Enterprise (contactar ventas)

Casos de uso avanzados: Reducto



Periódicos históricos

- Layouts multi-columna complejos
- Calidad de escaneo variable
- Fonts antiguos y deteriorados



Reportes financieros

- Tablas con celdas fusionadas
- Gráficos embebidos
- Múltiples formatos en un documento



Documentos legales

- Estructuras jerárquicas complejas
- Anotaciones y marcas manuscritas
- Formatos no estándar

Diferenciador: Cuando Tesseract y Mistral no son suficientes, Reducto maneja los casos extremos con precisión enterprise-grade

Comparativa final: ¿Cuál elegir?

Tesseract + LLM

Ideal para:

- Grandes volúmenes consistentes
- Presupuesto limitado
- Control total del pipeline
- Documentos con formato predecible

Mistral OCR

Ideal para:

- Documentos multimodales complejos
- Necesidad de precisión inmediata

Reducto

Ideal para:

- Documentos "imposibles"
- Casos enterprise críticos
- Layouts extremadamente complejos
- Presupuesto enterprise

Recomendación:

Prototipo → Mistral OCR

Producción high-volume → Tesseract

Casos complejos → Reducto